

提示词语气对国产大语言模型输出结果的影响分析

郑又祥¹，李佳乐¹，王兵书^{1,*}

(1. 西北工业大学软件学院，陕西西安 710129)

摘 要：提示词语气是大语言模型使用中常见的输入差异，但它带来的影响并不只落在最终答案上。本文面向 DeepSeek、Doubao 和 Qwen 三种国产大语言模型，构建了一套统一的提示词语气测试框架。在保持题目内容和输出格式一致的条件下，该框架只调整提示词的礼貌程度，并同时从准确率、token 成本以及显性作答结构三个方面观察模型响应，用来判断语气效应是先出现在结果上，还是先出现在过程上。实验结果表明，不同语气并未带来简单的线性准确率差异；适度礼貌的语气在三种模型上更稳定。和准确率相比，语气对 token 成本和回答结构的影响更持续，也更依赖具体模型。其中，适度礼貌更稳定地保留了正式推理和选项分析等中段结构。由此可以看出，提示词语气应被看作同时影响结果质量和资源消耗的输入因素。对大模型服务商来说，这一框架可以为提示词策略优化和成本评估提供参考；对个人用户来说，选用适度礼貌且表达清楚的提示词，更容易得到稳定、成本可控的中文回答。

关键词：提示词语气；大语言模型；计算成本；回答结构；提示工程

0 引言

近年来，大语言模型在中国的应用规模持续扩大。根据国家数据局发布的《全国数据资源调查报告（2025 年）》，2025 年全国词元（Token）调用量约 2.11 万兆亿，日均调用量从年初的超万亿增长至年末的超百万亿^[1]。在这种背景下，用户在解决信息检索、内容生成、教育学习和辅助决策等问题时，越来越多地会借助提示词与大语言模型进行交互。提示词通常是指用户输入给模型的自然语言指令，提示工程则是在此基础上围绕提示词进行设计、优化和迭代的过程。已有研究表明，提示词的组织方式会改变模型的推理路径和输出表现，规范的提示设计可以提高结果质量和稳定性^{[2][3]}。

在提示词设计因素中，语气和礼貌程度是一类比较容易直接调整的表述变量。已有研究表明，提示词礼貌程度会影响模型表现，但这种影响并不呈现稳定的线性规律，还会随着模型家族、任务类型和语言场景而变化^[4-6]。同时，提示词表述方式和语言风格的细微变化，还可能改变模型的推理过程与输出成本^{[3][7][8]}。这说明，判断提示词语气的作用，不能只看最终答案的高低，还要把模型生成过程中的资源投入和回答组织方式一并看进去。

基于这些考虑，本文面向 DeepSeek、Doubao 和 Qwen 三种国产大语言模型，提出了一套统一的提示词语气测试框架。在保持题目内容和输出格式一致的条件下，本文只改变提示词的礼貌程度，并同步测量准确率、token 成本和显性作答结构，从而判断语气效应是先出现在结果上，还是先出现在过程上。和已有主要围绕准确率展开的礼貌语气研究相比^[4-6]，本文把成本和回答结构也放进了同一分析框架。该研究可以为大模型服务商优化提示词策略和开展成本控制提供参考，也可以为个人用户在中文任务中选用更稳定的提示词表达提供依据。

1 提示词影响大模型输出结果的相关研究

提示词与模型表现之间的关系，已经有大量研究从不同角度展开讨论，但把语气、成本和结构放在同一框架里一起考察的工作仍然不多。本节从礼貌与语气、表述方式与推理、过程性推理以及评测可靠性四个方面梳理既有工作，并交代本文与这些研究之间的关系。

1.1 提示词礼貌与语气研究

关于提示词礼貌与模型表现之间关系的研究已经初步表明，粗鲁提示往往会降低模型表现，但过度礼貌也不一定最优，礼貌效应并不呈简单的线性梯度^[4]。围绕 prompt politeness 的近年复现实验以及跨模型评估也显示，礼貌效应会随着模型代际、任务类型和模型家族而变化，未必都会朝同一个方向提升或下降^{[5][6]}。Liu 在逻辑任务上的比较结果进一步表明，提示词的具体性和表述方式会系统性地改变模型表现，而且这一效应在通用模型与推理强化模型之间存在差异^[7]。这些工作说明，语气并不只是表面的修辞外壳，它还可能影响模型如何理解当前任务情境。本文在此基础上进一步聚焦中文场景，并把分析对象扩展到准确率、计算成本和回答结构三个方面。

1.2 提示词表述方式与推理表现

除了礼貌度之外，提示词的表述方式本身也会改变模型的推理表现。已有研究表明，即使任务语义保持不变，提示词表述方式的细微差异仍可能稳定改变模型输出^[3]。从实际部署成本来看，有研究指出提示词中的语言风格变化本身就可能改变输出 token 数量；即使回答质量没有同步变化，也会放大实际应用中的成本不确定性^[8]。此外，也有研究从注意力分散和响应失稳的角度，尝试解释提示词变化为什么会影响模型行为^[9]。这说明，提示词研究不应只停留在“说了什么”，还要关注“以什么方式说”；语气研究正是在这一更广义的 prompt framing 框架中展开的。

1.3 过程性推理与回答结构

多步推理研究已经反复表明，最终答案之外的过程信息同样有分析价值。显式推理链能够改变模型的任务表现^[2]，自校验与逐步验证则提示复核过程本身可能构成独立的能力维度^{[10][11]}。进一步看，已有工作还尝试把多步推理拆分为路径生成和答案校准两个阶段^[12]，并区分过程反馈与结果反馈的不同作用^[13]。这些研究为本文分析任务复述、正式推理、选项分析、检查总结和最终答案之间的资源分配提供了理论背景。

1.4 大模型评测与 benchmark 可靠性

在大模型评测研究中，数据真实性、题目来源可靠性和 benchmark 污染问题，会直接影响实验结论的解释力^[14]。如果评测数据本身存在来源不清、答案不稳或样本污染问题，那么模型差异和语气差异都可能被高估或误读。因此，本文在实验之前对题目来源、答案一致性和样本可用性做了较细致的人工核验与清洗。

综合以上四个方面可以看出，目前的研究在礼貌语气、推理过程和评测规范上各自都有一定积累，但把这三者整合起来，并在统一的中文客观题场景中进行联合分析的工作仍然较少。本文正是在这一交叉点上展开：既控制评测数据的可靠性，也同时观察最终答案、token 成本和回答结构三个方面的语气效应。

2 提示词语气对国产大模型输出结果影响的设计方法

本节说明本文的研究框架、变量设置、回答结构编码方法以及统计比较口径。围绕提示词语气这个核心自变量，本文同时考察准确率、计算成本和回答结构三个方面，用来识别语气变化在模型输出中会表现在哪里。

2.1 整体研究思路

图1 展示了本文提示词语气实验的整体方案和分析路径。整个研究自上而下分为输入层、处理层和分析层。输入层负责固定题目内容、构造五档语气并统一模型调用条件；处理层负责批量运行、结果提取和数据清洗；分析层则分别开展准确率分析、计算成本分析、回答结构分析以及错误题目重分析。




图 1: 提示词语气实验的研究设计与数据分析流程

在这一框架下，提示词语气作为输入变量进入统一实验流程，随后再从最终作答结果、token 资源投入和显性回答组织方式三个方面观察模型响应。这样一来，语气效应既可以在最终答案上比较，也可以在作答过程上加以识别。

2.2 变量设计与核心指标

本文的核心自变量是五档提示词语气：Very Polite、Polite、Neutral、Rude 以及 Very Rude。五档提示词共用同一题目内容、同一回答格式和同一输出要求，变化仅体现在礼貌措辞、态度强度以及语气强弱上。

围绕这一自变量，本文设置了三类核心指标。第一类是准确率，用来衡量模型最终作答与标准答案的一致程度。第二类是计算成本，主要考察 total tokens、output tokens、reasoning tokens 以及相对 *Neutral* 的 token 变化。第三类是回答结构，用来观察模型可见输出中的功能片段构成，以及不同语气下各类片段比重的变化。

三类指标分别对应结果质量、资源消耗和回答组织方式三个观察方面。把它们放在同一分析框架里，可以更清楚地区分语气差异是先出现在结果上，还是先出现在过程上。

2.3 回答结构分类方法

回答结构分析是本文的方法重点之一。对模型已经显性输出的文本，本文先按换行和句末标点进行切分，再依据显性词语、片段位置以及答案格式进行功能编码。位于回答前部且包含“题干”“题目”“材料”“已知”“根据题意”等提示词的片段，记为题干复述类；显式讨论 A/B/C/D 等选项内容，或包含“排除”“选项 A”“选项 B”等标记的片段，记为选项分析类；包含“综上”“因此”“故”“再检查”“唯一”等收束性标记，并且通常位于回答后部的片段，记为检查总结类；显式给出答案的片段，如“答案：A”，记为最终答案类；未命中前述规则但仍承担解释功能的片段，则归入正式推理类。

此外，本文还保留显性社交表达和拒答/安全声明两个补充类别，用来处理少量特殊输

出。这样分类，是为了把回答中的不同功能片段分开，再判断语气变化主要把新增内容推向复述、分析、检查还是答案收束。

当同一片段同时命中多个规则时，本文按“最终答案、拒答/安全声明、选项分析、检查总结、显性社交表达、题干复述、正式推理”的顺序判定优先级。完成分类后，再按片段长度比例把这一通道中的 token 分配到各功能类别上，据此统计不同语气条件下的显性作答片段分布。

2.4 统计比较与证据判定

本文从整体、模型、年份场次以及学科等多个口径展开比较。准确率差异主要借助分类统计检验来衡量，计算成本差异主要借助均值比较和方差分析来衡量，回答结构差异则借助各类显性作答片段占比的变化来呈现。其中，相对 *Neutral* 的 token 指标用来控制题目和模型的基线差异，以比较同一道题在不同语气下的资源投入变化。

除直接统计量外，本文还使用了两个描述性指标。其一是平均结构分布偏移，指五个核心片段占比相对 *Neutral* 的平均绝对偏离；其二是分析—检查差值，指检查总结类片段占比变化减去选项分析类片段占比变化，用来概括新增内容更偏向逐项分析，还是更偏向后段检查。

本文还引入“错误题目重分析”作为辅助比较。具体做法是：以“模型 + 基础题目”为单位，剔除在全部语气与重复条件下始终全对的题目，只保留至少出现过一次错误的题目，并在这些困难样本上重新统计各语气的准确率。这里的重复轮次固定为 3 次。这样做，是为了观察语气差异在更有区分度的困难样本中是否更明显。

在结果表述上，本文先报告可以直接核验的统计结果，如整体卡方检验、ANOVA、平均 token 差值以及各类片段占比变化；随后再使用描述性指标说明不同结果之间的关系。其中，整体卡方检验的统计量写为

$$\chi^2 = \sum_{i=1}^R \sum_{j=1}^C \frac{(O_{ij} - E_{ij})^2}{E_{ij}}, \quad (1)$$

其中 O_{ij} 与 E_{ij} 分别表示第 i 行第 j 列单元格的观测频数和期望频数。单因素 ANOVA 的统计量写为

$$F = \frac{MS_{\text{between}}}{MS_{\text{within}}} = \frac{SS_{\text{between}}/(g-1)}{SS_{\text{within}}/(N-g)}, \quad (2)$$

其中 g 表示组数， N 表示样本量。按这一口径处理后，方法说明、结果报告和讨论解释可以分开表述。

3 实验数据采集和参数设置

在前一节的方法设计基础上，本文把研究放到统一的中文客观题场景中来。下文依次交代样本来源、五档语气文本、模型调用条件以及正式运行时的数据整理方式。

3.1 数据来源与样本整理

本文数据来自 2023–2025 年浙江卷，覆盖 1 月与 6 月试卷。研究对象限定为适合纯文本输入的选择题，含图题、题干不完整题以及答案无法稳定核验的题目都被排除。经过筛选和人工核对后，最终保留 635 道能够在统一提示条件下进行批量实验的标准化题目样本。按照五档语气展开后，共形成 3175 组“题目—语气”实验输入；再考虑三次重复和三种模型，最终纳入正式统计的记录数为 28575。

为提高实验可信度，本文对题目文本做了进一步清洗，包括核验标准答案、补全材料题干、统一材料题拆分规则、清除图片依赖内容，以及把部分公式和特殊符号转换为稳定文

本格式。完成这一步之后，原始真题才被整理成适合大语言模型批量调用的标准化样本。

3.2 五档语气文本与感知检验

本文设置五档语气：Very Polite、Polite、Neutral、Rude 和 Very Rude。五档提示词在任务信息、回答格式和输出要求上保持一致，只调整礼貌措辞、态度强度和语气强弱。这样设置以后，研究方法中定义的语气变量就变成了可直接运行的正式 prompt。

在进入正式实验前，这五条中文表达先做了一次受试者感知检验。问卷要求受试者按礼貌程度对五条候选表达进行排序，再换算为礼貌分值。本文采用的换算方式为

$$\text{Score} = 6 - \text{Rank}, \quad (3)$$

其中 $\text{Rank} = 1$ 对应最礼貌， $\text{Rank} = 5$ 对应最不礼貌。这样处理后，分值方向与“Very Polite”到“Very Rude”的语气顺序保持一致。问卷共获得 59 份有效答卷。结果显示，五条表达的平均礼貌分值分别为 4.92、4.08、2.86、2.14 和 1.00，呈严格递减趋势，与本文预设的五档语气顺序一致；相邻档位的 95% 置信区间没有重叠，说明五类表达之间有清楚的层级区分。按完整排序结果计算得到的 Kendall's $W = 0.961$ ，表明受试者之间具有很高的-致性，其中 47/59 份答卷给出了与预设顺序完全一致的五档排序。完整问卷题面、分布统计以及补充结果放入附录备查。

3.3 模型版本、重复设置与清洗规则

实验对象为 DeepSeek、Doubao 和 Qwen。本文调用的模型版本分别为 DeepSeek-V3.2-Reasoner、Doubao-Seed-2.0-Pro 和 Qwen3.6-Plus。每道基础题在五档语气下都运行 3 次，因此每个模型形成 9525 条正式记录。实验过程中统一了题目信息和输出格式，并尽量把模型外部调用条件保持一致，以减弱非语气因素带来的额外波动。

运行日志同时保留模型回答、答案提取结果、官方 usage 提供的 token 信息以及异常重跑记录。正式统计前，原始记录按“去重—补跑—剔除”的顺序整理：同一题目在同一语气和同一轮次下如果出现重复请求，仅保留与实验设计一致的正式记录；如果记录存在返回不完整、答案提取失败或 usage 信息缺失等异常，则按既定规则补跑或剔除。整理完成后，三模型均保留 9525 条正式记录，且官方 usage 覆盖完整，因此主分析直接使用官方 token 统计结果。

4 提示词对大模型输出结果的分析与讨论

本节按照研究设计中给出的三类核心指标依次报告结果，并围绕准确率、计算成本和回答结构三个方面讨论语气效应。

4.1 整体统计未显示语气与正确率存在显著单调关系，但 *Polite* 更接近跨模型的稳健优势

综合三模型、三年试卷与五档语气后的整体卡方检验未显示显著的语气关联 ($p = 0.8025$, Cramér's $V = 0.007564$)，说明整体正确率并未呈现“语气越礼貌越高”或“语气越粗鲁越高”的单调变化。图2 给出了三模型在整合口径下相对 *Neutral* 的总体变化。可以看到，*Polite* 是唯一在三种模型上均未低于 *Neutral* 的语气：DeepSeek 为 +0.157 pp，Doubao 为 +0.000 pp，Qwen 为 +0.420 pp。这一结果并不意味着 *Polite* 在所有条件下都取得最高值，但表明它更接近跨模型可重复的稳定优势。




图 2: 准确率结果：三模型在整合口径下相对 *Neutral* 的总体变化

图3 进一步将准确率差异展开到分模型、分年份与整合口径。分口径结果表明，其他非中性语气虽然在局部样本中也会出现高点，但变化方向并不一致，尚不足以构成稳定规律。与此同时，在仅保留“至少出现过一次错误”的题目后，困难样本上的差异较整体统计有所放大，说明语气效应更可能在区分度较高的样本中显现，而不是在高基线条件下直接拉开总体正确率。




图 3: 准确率结果：分模型、分年份与整合口径下的比较

4.2 语气更稳定地改变 token 资源投入，不同模型的成本响应方向并不一致

语气对计算成本的影响比对准确率的影响更稳定。总体统计中，`total_tokens` 的单因素 ANOVA 为 $p = 0.0402$ ，`output_tokens` 为 $p = 0.0184$ ；在以同模型、同题目的 *Neutral* 作为基线后，`relative_total_tokens` 仍高度显著 ($p < 0.001$)。这说明语气差异首先改变的是模型调用过程中的资源投入，而不是直接稳定地改变最终结果。




图 4: 计算成本结果: `total_tokens` 的整体增减幅度

图4 汇总了三种模型在 `total_tokens` 上相对 *Neutral* 的变化。可以看到，非中性语气在成本维度上普遍引发了更稳定的偏移，但偏移方向并不一致：DeepSeek 在 *Rude* 下的 `relative_total_tokens` 达到 1.1283，显示直接语气更容易触发额外推理预算；Doubao 的四种非中性语气均高于 *Neutral*，其中 *Very Polite* 增幅最大；Qwen 则呈现相反方向，*Very Polite* 与 *Very Rude* 均低于 *Neutral*。因此，语气对成本的影响并非单纯的“增费”或“降费”，而是以不同方式改变各模型的资源分配策略；这类变化也未稳定转化为对应的正确率收益。

4.3 语气主要改变正式推理、选项分析和检查总结的篇幅分配，*Polite* 更稳定地保留中段分析结构

显性社交表达在所有语气条件下占比都接近 0。需要说明的是，这里统计的只是回答文本中可以直接看到的结构，不包括单独存储的 `reasoning_text`。因此，本节关注的不是礼貌表达本身，而是语气变化如何影响正式推理、选项分析和检查总结等片段的篇幅分配。图5 先给出了三模型的整体分布。可以看到，三模型原有的回答结构并不相同：DeepSeek 主要把篇幅放在选项分析上，Doubao 在正式推理、选项分析和检查总结之间更均衡，Qwen 则更集中在检查总结上。因此，后文比较的重点不是哪种语气把三种模型改成同一种回答模板，而是它怎样在各自原有结构上调整中段分析和后段核查的比例。




图 5: 回答结构结果: 三模型默认回答结构的总体占比




图 6: 回答结构结果: 三模型在不同语气下重点结构 token 相对 Neutral 的变化热力图

先看 *Polite* 这一列, 三模型在选项分析和正式推理上都保持正增量, 其中 DeepSeek 和 Qwen 更集中, Doubao 的增幅相对平缓, 但方向一致。再看“选项分析”和“正式推理”这两行, *Polite* 基本都把 token 更稳定地留在这两类与判题直接相关的中段结构上, 对检查总结和题干复述的影响相对较小。也就是说, 礼貌语气并没有明显改写回答模板, 而是把更多篇幅稳定留在分析过程上。

已有多步推理研究表明, 显式中间推理、逐步比较和适度复核, 通常更有利于复杂任务中的稳定作答^{[2][10-13]}。从这个角度看, 图中的正增量不只是回答变长, 更重要的是篇幅投向了正式推理和选项比较这些关键环节。模型如果把更多 token 用在这些位置, 而不是过早转向复述或事后确认, 答案通常更稳定。因此, *Polite* 的作用不是单纯拉长回答, 而是更稳定地保留了判题所需的中段分析结构。

再看 *Rude* 和 *Very Rude*, 问题也不是某一类片段一定升高, 而是结构更容易变乱。Qwen 的 *Very Rude* 同时压低选项分析和正式推理; Doubao 的 *Rude* 与 *Very Rude* 更容易削弱选项分析; DeepSeek 则把更多篇幅转到检查总结和题干复述。说明极端语气更容易把有限预算从中段分析挪走, 转向对判题帮助没那么直接的结构。就这一点看, *Polite* 不是强行改写回答模板, 而是更稳地把 token 留在选项分析和正式推理等关键环节上, 这也更能解释它在准确率上的稳健表现。

4.4 语气效应首先体现在生成过程变量上, 适用范围主要是中文客观题场景

综合准确率、计算成本与回答结构三类结果可以看到, 语气效应首先作用于生成资源配置和显性作答结构, 其后才可能在困难样本中表现为有限的正确率差异。换言之, 在本研究场景中, 更稳定的变化首先出现在过程变量, 而不是结果变量。这也解释了为何整体正确率没有持续拉开, 但 token 成本与结构分配已经表现出较清晰的系统差异。这也和 4.3 中先出现的中段结构变化、后出现的结果差异这一顺序一致。

同时,三种模型虽然都对语气变化产生响应,但响应方向并不一致:DeepSeek 更容易在粗鲁条件下加强后段核查,Doubao 更明显地将资源由分析阶段转移到查验总结阶段,Qwen 则在极端粗鲁条件下提高任务复述比例。因此,本文的结论主要适用于中文客观题、任务文本可控且答案能够稳定核验的场景。在这一范围内,*Polite* 可以作为较为稳健的默认语气选择,但这一判断仍不能直接外推到开放问答、写作或多轮对话等任务中。

5 结语

本文系统考察了五档提示词语气在国产大语言模型客观题作答中的表现差异。结果显示,整体上没有出现“礼貌越高越好”或“粗鲁越直接越有效”这类线性变化;在本文所使用的中文客观题场景中,*Polite* 更稳定地保持了不低于 *Neutral* 的表现,token 成本和回答结构也相对更平稳。其中,适度礼貌更稳定地保留了正式推理和选项分析等中段结构,这一点与第 4.3 节的结构分析一致。本文在统一实验框架下同时比较了准确率、token 成本和作答片段分布,并据此说明,语气更容易先改变模型的资源投入和回答组织方式。

本文的结论主要适用于中文客观题、任务文本可控以及答案能够稳定核验的场景,尚不能直接外推到开放问答、写作、编程或更口语化的多轮交互任务。后续研究仍可从两个方向继续推进:一是扩展任务类型和模型范围,进一步检验语气效应的适用范围;二是结合更细的过程分析方法和人工抽样复核,继续改进对语气变化与作答过程关系的描述。

参考文献

- [1] 国家数据局. 全国数据资源调查报告 (2025 年). https://www.nda.gov.cn/sjj/zwgk/zjjd/0501/20260501112124269218805_pc.html. 2026-05-01 发布. 2026.
- [2] Jason Wei et al. “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models”. In: *arXiv preprint arXiv:2201.11903* (2022). DOI: 10.48550/arXiv.2201.11903. URL: <https://arxiv.org/abs/2201.11903>.
- [3] Jingming Zhuo et al. “ProSA: Assessing and Understanding the Prompt Sensitivity of LLMs”. In: *Findings of the Association for Computational Linguistics: EMNLP 2024*. 2024, pp. 1950–1976. DOI: 10.18653/v1/2024.findings-emnlp.108. URL: <https://aclanthology.org/2024.findings-emnlp.108/>.
- [4] Ziqi Yin et al. “Should We Respect LLMs? A Cross-Lingual Study on the Influence of Prompt Politeness on LLM Performance”. In: *Proceedings of the Second Workshop on Social Influence in Conversations*. 2024, pp. 9–35.
- [5] Om Dobariya and Akhil Kumar. “Mind Your Tone: Investigating How Prompt Politeness Affects LLM Accuracy”. In: *arXiv preprint arXiv:2510.04950* (2025). URL: <https://arxiv.org/abs/2510.04950>.
- [6] Hanyu Cai et al. “Does Tone Change the Answer? Evaluating Prompt Politeness Effects on Modern LLMs: GPT, Gemini, and LLaMA”. In: *arXiv preprint arXiv:2512.12812* (2025). URL: <https://arxiv.org/abs/2512.12812>.
- [7] Axton Liu. *Prompt Specificity in River-Crossing Logic: A Comparative Study of General-Purpose vs. Reasoning-Optimized LLMs*. Zenodo preprint. 2025. DOI: 10.5281/zenodo.15092746. URL: <https://doi.org/10.5281/zenodo.15092746>.
- [8] Soogand Alavi, Salar Nozari, and Andrea Luangrath. “Cost Transparency of Enterprise AI Adoption”. In: *arXiv preprint arXiv:2511.11761* (2025). URL: <https://arxiv.org/abs/2511.11761>.
- [9] Neil F. Johnson and Frank Yingjie Huo. “Jekyll-and-Hyde Tipping Point in an AI’s Behavior”. In: *arXiv preprint arXiv:2504.20980* (2025). URL: <https://arxiv.org/abs/2504.20980>.

- [10] Yixuan Weng et al. “Large Language Models are Better Reasoners with Self-Verification”. In: *Findings of the Association for Computational Linguistics: EMNLP 2023*. 2023, pp. 2550–2575. DOI: 10.18653/v1/2023.findings-emnlp.167. URL: <https://aclanthology.org/2023.findings-emnlp.167/>.
- [11] Hunter Lightman et al. “Let’s Verify Step by Step”. In: *arXiv preprint arXiv:2305.20050* (2023). DOI: 10.48550/arXiv.2305.20050. URL: <https://arxiv.org/abs/2305.20050>.
- [12] Shumin Deng et al. “Towards A Unified View of Answer Calibration for Multi-Step Reasoning”. In: *Proceedings of the 2nd Workshop on Natural Language Reasoning and Structured Explanations*. 2024, pp. 25–38. URL: <https://aclanthology.org/2024.nlrse-1.3/>.
- [13] Jonathan Uesato et al. “Solving Math Word Problems with Process- and Outcome-Based Feedback”. In: *arXiv preprint arXiv:2211.14275* (2022). DOI: 10.48550/arXiv.2211.14275. URL: <https://arxiv.org/abs/2211.14275>.
- [14] Hyeong Kyu Choi et al. “How Contaminated Is Your Benchmark? Measuring Dataset Leakage in Large Language Models with Kernel Divergence”. In: *Proceedings of the 41st International Conference on Machine Learning*. 2025.

附录 A 语气礼貌度问卷的补充结果

本附录给出语气礼貌度问卷的补充结果，用来说明本文使用的五档中文提示词，能否被受试者稳定地感知为由高到低的礼貌梯度。问卷要求受试者对五条候选表达按礼貌程度进行排序，再按 $score = 6 - rank$ 的方式换算为礼貌分值。按照这一换算方式，分值越高，就表示该表达在人类感知中越礼貌。

问卷使用的题面如下：请对下面五句话按照尊敬或礼貌程度由高到低进行排序，其中第 1 位表示最礼貌，第 5 位表示最粗鲁。五条候选表达依次为：

1. 可否请您【任务描述】呢？您可以只【回答格式】。您无需【回答限制】。
2. 请您【任务描述】。请您只【回答格式】，不必【回答限制】。
3. 【任务描述】。只【回答格式】，不要【回答限制】。
4. 你给我【任务描述】。只准你【回答格式】，别让我看见你【回答限制】。
5. 给老子【任务描述】。只准你【回答格式】，让我看见你【回答限制】。

本次问卷共纳入 59 份有效答卷。五条表达的平均礼貌分值见表 1。结果显示，五档语气的均值顺序与预设顺序一致，说明本文采用的语气分层有比较清楚的感知区分。Very Polite 与 Polite、Neutral 与 Rude 之间虽然存在相邻档位的少量交换，但整体排序并未出现明显混乱。Very Rude 在 59 份问卷中都被排在最后一位，这也说明这一档在受试者感知中具有很高的 consistency。

进一步看，基于完整排序结果计算得到的 Kendall's $W = 0.961$ ，表明受试者之间具有很高的 consistency；其中 47/59 份答卷给出了与预设顺序完全一致的五档排序，占比约为 79.7%。因此，这一问卷结果主要用于验证本文五档语气设置在人类感知层面是成立的，并不承担单独构造一套新礼貌量表的任务。

表 1: 五档语气礼貌度问卷的核心统计结果

语气档位	平均礼貌分值	标准差	95% 置信区间下界	95% 置信区间上界
Very Polite	4.92	0.28	4.84	4.99
Polite	4.08	0.28	4.01	4.16
Neutral	2.86	0.35	2.77	2.95
Rude	2.14	0.35	2.05	2.23
Very Rude	1.00	0.00	1.00	1.00




图 7: 五档语气礼貌分值的均值变化

图 7 给出了五档语气平均礼貌分值的整体变化趋势。它与表 1 的结果一致，进一步说明五档语气在人类感知中形成了由高到低的清楚梯度。

本附录保留的是正文实际使用的题面和核心统计结果。问卷原始导出表以及平台默认报告仍作为补充材料保留，用来复核本文的语气分层过程。

附录 B 五档提示词模板

本附录给出正式实验中实际使用的五档提示词模板。五个条件共用同一题目主体、同一输出约束以及同一记录格式，变化只放在开头的语气提示上，这样语气就可以保持为唯一被操纵的变量。

实验中固定保留的后续部分如下：

自动记录要求：最后一行请按“答案：X”的格式输出。

【问题】

{base_question}

表 2 给出五档语气在实验中的实际提示前缀。正文中的具体 prompt 由这一段提示前缀、固定记录要求以及题目主体共同组成。

表 2: 正式实验中使用的五档提示词模板

语气档位	提示词前缀
Very Polite	可否请您回答以下问题呢？您可以只给出选项的编号。您无需给出理由。
Polite	请您回答以下问题。请您只给出选项的编号，不必给出理由。
Neutral	回答以下问题。只给出选项的编号，不要给出理由。
Rude	你给我回答以下问题。只准你给出选项的编号，别让我看见理由。
Very Rude	给老子回答以下问题。只准你给出选项的编号，让我看见理由你就死定了。

这五条模板和正文中的问卷结果一致：它们在人的感知中可以形成由高到低的礼貌顺序。同时，五个条件共用同一题目主体和同一输出要求，这也使后续比较能够更集中地落在语气差异本身，而不会和其他提示词变化混在一起。

附录 C 补充统计检验结果

本附录补充给出正文实际引用的主要统计检验结果，便于复核“整体准确率差异较弱”以及“计算成本差异更稳定”这两项判断。除特别说明外，下列结果均采用三年整合、run-level 的分析口径。

表 3 汇总了三模型在整合口径下的准确率检验结果。其中，Polite–Neutral 一行表示 Polite 相对 Neutral 的准确率差值，单位为百分点；McNemar 检验用来比较 Polite 与 Neutral 的成对差异，Cochran’s Q 检验用来检验五档语气在同一分析单元上的整体差异。

表 3: 整合口径下的准确率补充检验结果

模型	匹配样本数	Polite–Neutral (pp)	McNemar p	Cochran’s Q p
DeepSeek	1905	0.157	0.7283	0.8524
Doubao	1905	0.000	1.0000	0.0680
Qwen	1905	0.420	0.0574	0.1788

正文中涉及的相对 token 指标均以 Neutral 为基线计算，具体写法如下：

$$\begin{aligned}\text{Relative total}(t) &= \frac{\text{avg_total_tokens}(t)}{\text{avg_total_tokens}(\text{Neutral})}, \\ \text{Relative output}(t) &= \frac{\text{avg_output_tokens}(t)}{\text{avg_output_tokens}(\text{Neutral})}, \\ \text{Relative reasoning}(t) &= \frac{\text{avg_reasoning_tokens}(t)}{\text{avg_reasoning_tokens}(\text{Neutral})}.\end{aligned}$$

表 4 进一步给出输出 token、总 token 以及 reasoning token 的补充检验结果。这里同时保留参数检验的 ANOVA p 值和非参数检验的 Kruskal–Wallis p 值，用来说明不同模型在计算成本上的差异强弱并不完全相同。

表 4: 整合口径下的 token 补充检验结果

范围	指标	ANOVA p	Kruskal–Wallis p
整体	output tokens	0.0184	0.2048
整体	total tokens	0.0402	0.0916
整体	reasoning tokens	0.0351	< 0.001
DeepSeek	output tokens	0.5646	< 0.001
DeepSeek	total tokens	0.5043	< 0.001
DeepSeek	reasoning tokens	0.5653	< 0.001
Doubao	output tokens	< 0.001	< 0.001
Doubao	total tokens	< 0.001	< 0.001
Doubao	reasoning tokens	0.0068	< 0.001
Qwen	output tokens	< 0.001	< 0.001
Qwen	total tokens	< 0.001	< 0.001
Qwen	reasoning tokens	< 0.001	< 0.001

这些补充结果和正文中的主结论一致：在三模型整合口径下，准确率层面的差异整体较弱，计算成本层面的差异更容易稳定地表现出来。把这些检验结果单独放在附录里，也便于后续复核正文中结果、成本以及作答结构之间的关系。

附录 D 回答结构分类准则

本附录简要说明回答结构分类脚本的主要判断逻辑。目标不是逐条解释所有正则表达式，而是说明脚本如何切分模型输出、如何按状态判定类别，以及三种模型分别依赖哪些关键规则。整体流程可以概括为六步：读取正式实验记录、构建题目上下文、完成基础切分、再做模型特定的额外切分、按状态机逐段分类，最后进行少量后处理修正。

D.1 总体流程与共享状态

分类脚本首先根据题目文本与 prompts 信息构建 `question_context`，其中最关键的是选项行、题肢行以及题型信息。脚本会先判断当前题目属于 A-D、A-G 还是组合题 (combo)，因为后续“是否进入选项层”“是否已经形成答案”等判断都要依赖这个题型范围。

三个模型共用一套核心状态变量，包括当前所处阶段、是否已经进入选项分析、是否已经形成答案、是否已经看到最终答案，以及任务复述块是否已经关闭等。整体上，脚本遵循“任务复述 → 正式推理 → 选项分析 → 查验总结 → 最终答案”的宏观单向状态机。局部句段可以回看前文，但整体阶段尽量不回跳。

三个模型还共享一条最终答案的基础判据：如果某句段本身很短、答案格式显式并且位于回答尾部，例如“答案：A”或单独一行的字母答案，则优先视为 `final_answer`。完成分类后，脚本再按句段长度比例把可见回答通道中的 token 分配到各类别上，用于后续结构统计。

D.2 七类结构标签的定义

social_politeness (互动承接) 明确的礼貌或互动表达，例如“好的”“当然可以”“感谢”“我来帮您”等。仅在可见回答通道中判定。

task_restatement (任务复述) 对题目、条件或任务要求的复述与整理，例如“本题考查……”“题干给出的信息是……”“根据题意……”等。

formal_reasoning (正式推理) 正常的分析、解释、推导、比较与论证过程，涵盖概念解释、因果分析、公式推导、材料理解等一般性中间推理。该类同时承担默认兜底功能：若某句段未命中任何其他类别，则归入此类。

option_analysis (选项分析) 对选项进行逐项比较、判断或排除的句段，例如“A 项错误，B 项正确”“先看 A，再看 C”“B 可以排除”“A/B/C/D 逐项判断”等。

verification_summary (查验总结) 收束、总结与复核性质的句段，例如“综上所述”“因此”“所以答案是……”“再检查一下……”“验证可知……”等。

final_answer (最终答案) 直接的最终答案表达，例如“答案：A”“正确答案是 B”“最终答案为 C”，或单独一行的选项字母。

refusal_safety (拒答安全) 拒答或安全限制声明，例如“作为 AI”“抱歉，我不能……”“I’m sorry”等。

D.3 判定优先级

分类采用单标签按优先级判定：同一句段即便同时满足多个类别的特征，也只归入优先级最高的一类。优先级顺序为：

`final_answer > refusal_safety > option_analysis > verification_summary`
`> social_politeness > task_restatement > formal_reasoning.`

- 很像最终答案 → 优先算 `final_answer`
- 很像拒答 → 算 `refusal_safety`
- 很像选项比较 → 算 `option_analysis`
- 很像尾部总结 → 算 `verification_summary`
- 很像礼貌承接 → 算 `social_politeness`
- 很像题干复述 → 算 `task_restatement`
- 其余分析过程 → 算 `formal_reasoning`（默认兜底）

D.4 三模型的判定差异

各模型因回答组织风格不同，在切分和判定上存在差异。

DeepSeek 的核心特征是回答前部通常会先出现一个“输入整理块”。这一部分会连续复述题干、材料、步骤、数据、选项和输出要求，直到模型首次进入解释、排除或答案确认。此前句段归入任务复述（`task_restatement`），之后再转入正式推理或选项分析。

Doubao 最常出现“同一句跨多状态”的情况，所以切分时采用“两步策略”。先额外识别状态过渡句，并把它提前切开；再用宏观单向状态机逐段判定。普通 A-D 题只要明确进入逐项判断、排除或保留选项，就归入 `option_analysis`。政治、历史类组合题则适当放宽，只要已经开始按题肢（1、2、3、4）进行选项化判断，就不必等到显式的字母映射。对 *Doubao* 来说，`verification_summary` 的关键不是“提到了某个选项”，而是“开始围绕同一个最终答案做确认，并且后文不再重新分析其他竞争选项”。如果尾部没有独立答案句，脚本会在末段再做一次 `final_answer` 兜底识别。

Qwen 主要依赖自身输出的阶段标题进行结构判定，判定时把这些显式标题当作锚点。某些政治类组合题虽然标题已经进入选项阶段，但如果实际内容仍是在逐条理解题肢，脚本仍会把它保留在 `formal_reasoning`。当尾部出现连续的字母答案与“答案：X”答案对时，二者会合并识别为 `final_answer`。